

# TER KAI — Sistema e Método para Governança Automatizada de IA e Trilha de Auditoria Verificável

**Inventor:** Gustavo Pratti de Barros

**Data de concepção:** novembro de 2025

**Categoria:** Individual (microentidade)

---

## 1. Campo da Invenção

A presente invenção refere-se a sistemas e métodos para **governança automatizada de modelos de inteligência artificial (IA) e registro verificável de decisões e métricas**.

Mais especificamente, trata-se de um mecanismo técnico que permite monitorar, validar e auditar, de forma contínua e criptograficamente comprovável, decisões e saídas produzidas por sistemas de IA em ambientes corporativos ou regulados.

---

## 2. Antecedentes da Invenção

Sistemas de IA modernos, especialmente os baseados em aprendizado de máquina e modelos de linguagem, são frequentemente considerados **caixas-pretas**: produzem resultados sem fornecer provas técnicas de como ou por que determinada decisão foi gerada.

Essa falta de rastreabilidade cria riscos legais, éticos e operacionais, dificultando a conformidade com normas como o **AI Act da União Europeia**, a **LGPD** e diretrizes de **auditoria e responsabilidade algorítmica**.

Atualmente, as soluções disponíveis tratam de partes isoladas do problema:

- **Plataformas de MLOps** registram experimentos, mas não geram provas verificáveis.
- **Ferramentas de observabilidade** monitoram métricas, porém sem rastreabilidade criptográfica.
- **Padrões regulatórios** (ex.: ISO 42001, NIST AI RMF) fornecem princípios, mas não implementações técnicas.

Dessa forma, permanece ausente um **sistema unificado que integre governança, verificabilidade e automação de conformidade técnica**.

---

### 3. Sumário da Invenção

O TER KAI propõe um **sistema operacional de governança de IA**, composto por módulos interconectados que garantem **decisões rastreáveis, auditáveis e tecnicamente verificáveis**. O sistema integra métricas, regras e auditoria digital, formando uma trilha de evidências criptográfica (*Proof-of-Processing Ledger* — *PoP-L*).


#### Componentes principais:

1. **MIR (Metrics & Insights Relay)**: coleta, padroniza e agrega métricas técnicas e contextuais de execução.
2. **Ω (Omega) Governance Engine**: aplica políticas expressas em linguagem CEL/JSONLogic, decidindo entre *ALLOW*, *REVIEW* ou *BLOCK*.
3. **DED (Decision Evidence Document)**: documento digital imutável contendo todas as evidências da execução.
4. **PoP-L (Proof-of-Processing Ledger)**: registro encadeado e carimbado por autoridade de tempo (TSA), assegurando autenticidade e integridade.
5. **HITL (Human-in-the-Loop)**: fluxo opcional de revisão humana, com registros de intervenção e override documentados.

O resultado é uma camada de governança capaz de **provar tecnicamente** que uma decisão automatizada foi executada sob critérios verificáveis, versionados e auditáveis.


### 4. Breve Descrição dos Desenhos (modo textual)

#### FIG. 1 — Visão geral do sistema (System Overview)




Representa o fluxo completo de dados desde a entrada até o registro verificável da decisão.

#### FIG. 2 — Fluxo de dados do MIR



#### FIG. 3 — Fluxo do motor Ω



[Decisão: ALLOW / REVIEW / BLOCK]

#### FIG. 4 — Integração DED + PoP-L

[DED JSON canônico] → [Hash SHA3-512] → [Assinatura digital + TSA]  
↓  
[Encadeamento no PoP-L (Merkle / Hash-Chain)]

#### FIG. 5 — Processo de revisão humana (HITL)

[Decisão marcada como REVIEW] → [Fila de revisão]  
↓  
[Avaliador humano aplica override]  
↓  
[Registro 'human\_override' no DED + Ledger]

---

## 5. Descrição Detalhada da Invenção

O sistema TER KAI opera em camadas:

### 1. Camada de Métricas (MIR):

- Recebe métricas técnicas (ex.: PII count, bias score, toxicidade, tempo de inferência).
- Padroniza todas as métricas em um formato canônico (`MetricsInput`).
- Envia para o módulo de governança ( $\Omega$ ).

### 2. Camada de Governança ( $\Omega$ ):

- Avalia políticas pré-configuradas (`PolicyConfig`) escritas em CEL/JSONLogic.
- Executa regras por prioridade, retornando uma decisão determinística.
- Mantém logs detalhados, fail-safes e controle de versões das políticas.
- (Código de exemplo presente no artefato “omega.service.ts” r1.2.)

### 3. Camada de Evidência (DED):

- Gera um documento digital com todos os campos de contexto, métricas, decisão e assinatura.
- Aplica serialização canônica e cálculo de hash determinístico.

### 4. Camada de Ledger (PoP-L):

- Registra cada hash no ledger imutável.
- Integra-se a uma Autoridade de Carimbo de Tempo (TSA) conforme RFC 3161.
- Implementa encadeamento de registros (*hash-chain*).

### 5. Camada de Revisão Humana (HITL):

- Permite revisão e intervenção humanas em casos de decisão *REVIEW*.
- Registra todas as ações (*human\_override*) no DED, garantindo auditoria completa.

O sistema pode operar em ambientes distribuídos (com filas, workers e bancos de dados independentes) e suporta migração/rotação segura de chaves de criptografia.

---

## 6. Exemplos de Implementação

### Exemplo 1 — Avaliação automática de política

- Entrada: `metricsInput.aggregated_metrics = { pii_count: 1 }`
- Política: `"metrics.pii_count > 0 → action = 'BLOCK'"`
- Resultado:  $\Omega \rightarrow$  `DecisionPayload = { action: 'BLOCK', ruleTriggered: 'PII Detectado' }`
- Registro: DED criado, hash SHA3-512 calculado e ancorado no PoP-L.

### Exemplo 2 — Revisão humana

- Saída marcada como *REVIEW* → fila HITL → operador aprova → campo `human_override = true` gravado.

### Exemplo 3 — Auditoria externa

- Auditor executa CLI de verificação:
    - recalcula hash do DED,
    - valida assinatura TSA,
    - reconstrói cadeia Merkle.
  - Resultado: comprovação matemática de integridade e autoria.
- 

## 7. Vantagens Técnicas

- **Rastreabilidade total:** cada decisão gera evidência criptograficamente verificável.
- **Conformidade automatizada:** políticas e métricas conectadas em tempo real.
- **Auditoria independente:** registros assinados por TSA e encadeados no ledger.
- **Fail-safe e override humano controlado:** decisões críticas sempre auditáveis.

- **Reprodutibilidade:** todas as execuções podem ser reproduzidas a partir do DED e do hash do modelo.
- 

## 8. Reivindicações (reserva para versão completa)

*(Esta seção será preenchida na aplicação “non-provisional”; incluímos apenas marcadores de reivindicações técnicas.)*

1. Método implementado em computador para governança automatizada de IA, conforme descrito nas seções anteriores.
  2. Sistema de registro criptográfico e encadeado para auditoria verificável de decisões automatizadas.
  3. Uso combinado de MIR,  $\Omega$ , DED e PoP-L para prover rastreabilidade e conformidade técnica.
- 

## 9. Informações do Inventor

**Inventor:** Gustavo Pratti de Barros

**Residência:** (inserir cidade/estado)

**Data:** novembro de 2025

**Categoria:** Individual (microentidade)

**Direitos de prioridade:** este documento estabelece prioridade de invenção para fins de depósito provisório na USPTO.

---

## Resumo (Abstract em português)

O presente sistema refere-se a um método e arquitetura de governança automatizada e verificável para decisões de sistemas de inteligência artificial. O sistema, denominado **TER KAI**, compreende uma cadeia integrada de módulos que coletam métricas de execução (MIR), aplicam políticas declarativas ( $\Omega$ ), geram evidências digitais determinísticas (DED) e ancoram resultados criptograficamente em um registro encadeado verificável (PoP-L). O método inclui a serialização canônica das evidências, cálculo de hash criptográfico e carimbo de tempo por autoridade confiável (TSA), permitindo auditoria independente e reconstrução de histórico. O sistema suporta intervenção humana rastreável (HITL), na qual decisões classificadas como revisão são documentadas com campo de substituição auditável (`human_override`). O ledger de auditoria utiliza encadeamento hash (Merkle chain) para assegurar integridade temporal e imutabilidade das evidências. A invenção proporciona governança e conformidade de IA de forma automatizada, verificável e reproduzível, aplicável a sistemas que exigem rastreabilidade, prova de integridade e controle de risco operacional ou ético em decisões automatizadas.

# Proposta de Claims (rascunho preliminar)

## Claim 1 — (Independent)

Um **método implementado por computador** para governança e auditoria de decisões de sistemas de inteligência artificial, compreendendo as etapas de:

1. receber, por um módulo de coleta de métricas (MIR), dados e indicadores técnicos de execução de modelo;
2. normalizar e agregar ditas métricas em um formato canônico;
3. avaliar, por um motor de governança ( $\Omega$ ), um conjunto de regras versionadas expressas em linguagem declarativa (CEL ou JSONLogic) sobre as métricas agregadas;
4. gerar uma decisão automatizada (*ALLOW*, *REVIEW* ou *BLOCK*), juntamente com a regra e a justificativa acionadas;
5. registrar a decisão, métricas e contexto em um documento digital de evidência (DED);
6. aplicar serialização determinística e calcular um hash criptográfico da evidência; e
7. submeter o hash resultante a uma autoridade de carimbo do tempo (TSA), registrando-o em um ledger encadeado (*Proof-of-Processing Ledger – PoP-L*).

---

## Claim 2 — (Dependent de Claim 1)

O método de acordo com a *claim 1*, no qual o **ledger** utiliza uma **cadeia de hashes encadeados (Merkle chain)** para prover integridade auditável e reconstrução verificável de cada decisão.

---

## Claim 3 — (Dependent de Claim 1)

O método de acordo com a *claim 1*, no qual a etapa de avaliação é realizada através de **programa CEL compilado em tempo de execução**, garantindo flexibilidade e isolamento de regras de política.

---

## Claim 4 — (Dependent de Claim 1)

O método de acordo com a *claim 1*, no qual o documento digital de evidência (DED) é **serializado em formato JSON canônico**, com ordenação lexicográfica de chaves e codificação Unicode NFC, assegurando determinismo na verificação de hash.

---

## Claim 5 — (Dependent de Claim 1)

O método de acordo com a *claim 1*, compreendendo adicionalmente uma etapa de **revisão humana (HITL)**, na qual decisões classificadas como *REVIEW* são enviadas a uma fila de intervenção

manual e, caso alteradas, o campo `human_override` é inserido no DED e novamente ancorado no ledger.

---

### Claim 6 — (Dependent de Claim 1)

O método de acordo com a *claim 1*, no qual os registros de ledger incluem um **identificador de auditoria imutável** (`auditLogId`) e um **ponteiro para o registro anterior**, garantindo integridade encadeada entre logs.

---

### Claim 7 — (Independent – System Claim)

Um **sistema de governança e auditoria de IA** compreendendo:

- um módulo MIR configurado para coletar e normalizar métricas;
  - um módulo  $\Omega$  configurado para aplicar políticas e gerar decisões;
  - um módulo DED configurado para gerar evidência digital canônica; e
  - um módulo PoP-L configurado para registrar hashes e carimbos de tempo em ledger verificável.
- 

### Claim 8 — (Dependent – Computer Program)

Um **meio legível por computador** contendo instruções que, quando executadas por um processador, implementam o método de qualquer uma das *claims 1–6*.

---

## Notas técnicas para fortalecer a proteção

- Os *claims 1 e 7* são os principais: cobrem o **método** e o **sistema**, respectivamente.
  - Os *claims 2–6 e 8* adicionam camadas de proteção para aspectos **criptográficos, determinísticos e humanos** do TER KAI.
  - Em combinação, cobrem tanto o **fluxo operacional** quanto a **implementação computacional** — permitindo bloquear cópias que tentem reproduzir o mesmo conceito sob outro nome.
-

## 1. Núcleo conceitual da invenção

O **TER KAI** é um sistema integrado que cria uma **trilha de auditoria verificável para decisões de IA**, combinando:

- coleta e padronização de métricas (MIR),
- avaliação de políticas declarativas ( $\Omega$ ),
- registro de evidência determinística (DED),
- ancoragem criptográfica e temporal (PoP-L),
- e fluxo de revisão humana auditável (HITL).

**Essência técnica:** governança de IA automatizada com **prova criptográfica e verificabilidade independente**, não apenas logging ou explicabilidade.

---

## 2. Termos técnicos-chave para pesquisa

### Palavras-chave em inglês (para USPTO/EPO/WIPO)

- “AI governance system”
- “automated decision audit trail”
- “machine learning compliance”
- “cryptographically verifiable decision record”
- “proof-of-processing ledger”
- “time-stamped audit log for AI models”
- “policy evaluation engine for AI”
- “human-in-the-loop override logging”
- “canonical JSON serialization for audit evidence”
- “verifiable AI risk governance framework”

### Classificações CPC/IPC relevantes

- **G06N 20/00** — IA aplicada à tomada de decisão
- **G06Q 10/06** — Sistemas de conformidade automatizada
- **G06F 21/62** — Segurança de dados e auditoria
- **H04L 9/32** — Assinaturas digitais / verificação de integridade

### 3. O que já existe (possíveis áreas de confusão)

| Categoria existente                                                          | O que faz                        | Por que não é o TER KAI                                   |
|------------------------------------------------------------------------------|----------------------------------|-----------------------------------------------------------|
| <b>MLOps platforms (ex. MLflow, Kubeflow)</b>                                | Rastreiam experimentos de modelo | Não geram evidências criptográficas nem carimbo TSA       |
| <b>AI explainability tools (ex. SHAP, LIME)</b>                              | Explicam decisões do modelo      | Não validam nem registram decisão verificável             |
| <b>Model governance frameworks (ex. NIST AI RMF, IBM watsonx.governance)</b> | Documentam políticas e risco     | Não implementam ledger criptográfico nem DED              |
| <b>Blockchain audit trails</b>                                               | Registram transações genéricas   | Não vinculam políticas de IA nem governança de decisão    |
| <b>Observability / Monitoring tools (ex. Prometheus, Datadog)</b>            | Monitoram métricas               | Não criam prova técnica nem trilha verificável de decisão |

### 4. Diferenciais técnicos exclusivos

| Eixo                           | Diferencial                                                                     | Evidência no TER KAI            |
|--------------------------------|---------------------------------------------------------------------------------|---------------------------------|
| Verificabilidade criptográfica | Ledger PoP-L com hash SHA3-512 + TSA                                            | Seção DED + PoP-L               |
| Governança automatizada        | Engine $\Omega$ com políticas CEL/JSONLogic versionadas                         | Código “omega.service.ts”       |
| Evidência determinística       | Serialização canônica (ordem lexicográfica, Unicode NFC)                        | Seção “canonical serialization” |
| Revisão humana auditável       | Campo <code>human_override</code> rastreável no ledger                          | Seção HITL                      |
| Encadeamento temporal          | Hash-chain / Merkle chain imutável                                              | Seção PoP-L                     |
| Modularidade interoperável     | MIR $\rightarrow \Omega \rightarrow$ DED $\rightarrow$ PoP-L integrados via API | Arquitetura FIG. 1              |

### 5. Frases-âncora para diferenciar nas buscas

Os pesquisadores devem procurar se **já existe algum sistema que combine** as expressões abaixo — a ausência de combinação indica **novidade**:

- “AI policy engine + cryptographic proof + timestamp authority”
- “verifiable audit trail + human override logging”
- “canonical serialization + deterministic hash of AI decision”
- “machine learning governance + hash-chain ledger”
- “proof-of-processing for AI model outputs”

---

## 6. Conclusão

**Objetivo da busca:** verificar se existe anterioridade **que combine governança de IA automatizada com trilha de auditoria criptográfica e evidência verificável.**

**Distintivo fundamental:**

O TER KAI **não** é apenas auditoria, nem blockchain, nem compliance regulatório: ele une todos esses conceitos num **pipeline técnico comprovável**, de coleta de métricas até ancoragem criptográfica e revisão humana.

---